

计算广告中的机器学习问题与方法

张伟楠¹ 任 侃² 张海峰³

¹ 上海交通大学

² 微软亚洲研究院

³ 北京大学

关键词：计算广告 互联网广告交易机制 机器学习

背景概览

美国百货公司之父约翰·沃纳梅克 (John Wanamaker) 有一句名言：“我知道有一半的广告费浪费了，但我不知道是哪一半。”这句话诠释了传统渠道的广告投放（如街头展板广告、电视广告等）无法细化投放粒度从而造成广告费浪费的问题。

计算广告 (computational advertising) 是一种运行在互联网上的高精度、细粒度的广告投放形式。与传统广告相比，计算广告充分借助了互联网媒体带来的诸多便利特性，可以针对不同用户展示不同的广告内容，以极细粒度的形式完成“千人千面”的广告展示。另一方面，通过合理的拍卖机制，计算广告平台使得广告主能够通过竞价的形式争取广告位，从而在经济上达到多方博弈的均衡局面^[1]。基于这些优势，计算广告极大程度地优化了广告投

放的效果。首先，它能够帮助广告主获得高价值的广告投放回报；其次，它能帮助媒体获得更高的广告收入；最后，它能让互联网用户避免不相关的劣质广告的轰炸，优化用户上网体验，从而达成计算经济层面多方共赢的局面。

美国互动广告局 (The Interactive Advertising Bureau, IAB) 是互联网广告领域的权威。其 2019 年公布的研究报告^[2]显示，2018 年全年，美国市场的互联网广告规模保持高速增长（相比 2017 年增长 21.8%），达到 1074 亿美元，远远超过电视广告（709 亿美元）、杂志广告（200 亿美元）等传统媒体广告的规模。

“计算广告”这个专业词汇是由谷歌公司的杰出科学家安德烈·布罗德 (Andrei Broder) 提出的。他在斯坦福大学开设的计算广告导论课程^[3]中指出，计算广告旨在探索用最好的技术来解决在具体场景

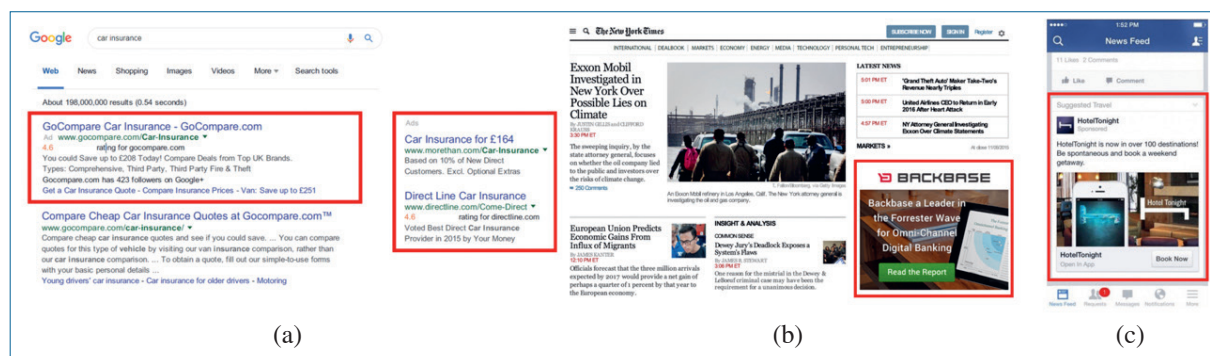


图 1 三种主要的计算广告形态：(a) 搜索广告；(b) 展示广告；(c) 移动端信息流广告

下的每个用户和合适的广告之间的最佳匹配这一核心挑战。为此,计算广告需要结合基于互联网大数据的机器学习及拍卖理论、博弈论、消费者行为学等学科前沿知识和技术。图1列举了三种计算广告的主要形式,即搜索广告、展示广告和移动端信息流广告。可以看到,无论是在搜索、网页浏览或者手机APP使用场景,平台都可以借助基于用户账户、Cookie或者手机ID等识别信息来收集用户的历史行为,训练机器学习模型,以充分预估用户对候选展示广告的喜好程度^[4];同时,结合互联网广告的拍卖机制,广告投放平台可以优化得到每个广告主最优的出价策略,从而将广告主的预算合理地分配到对其广告真正感兴趣的用户端,真正解决沃纳梅克提出的广告费浪费难题^[1]。

基础知识

随着互联网的日益普及,伴随互联网成长的计算广告也逐渐形成了成熟的广告形态、交易机制和计价规则。

广告形态

在互联网广告领域,主要存在图1所示的三种典型的广告形态。其中,搜索广告和展示广告主要呈现在个人电脑等桌面设备上,信息流广告则主要呈现在手机、平板电脑等移动设备上。

搜索广告是随着搜索引擎的兴起而出现的广告形态,是搜索引擎的重要变现渠道。用户在搜索引擎输入关键词后,得到的搜索结果列表的前几个位置通常是搜索广告的广告位。搜索广告的特点主要有:(1)有搜索关键词,可以用于广告的检索;(2)同时展示多个广告位,需要对广告列表进行排序。

展示广告可以出现在任何用户阅读的网页中,它的广告位通常是根据网页特殊定制的。与搜

索广告不同,展示广告没有对应的搜索关键词,且通常一次只展示一个广告而不是广告列表。由于展示广告嵌入在网页内容中,网页内容则可以作为检索广告的一种依据。

进入移动互联网时代,信息流成为了移动端流行的信息组织形式,信息流广告也应运而生。信息流广告兼具搜索广告和展示广告的一些属性,同时又有自身的特点。首先,信息流广告与搜索广告一样,可以视为由多个广告位组成的广告序列,需要对广告进行排序。其次,信息流广告与展示广告类似,将广告嵌入在用户阅读的网页(或信息流)内容中,因此可以将信息流内容作为检索广告的依据。最后,信息流广告具有持续互动的特性,即后续广告的检索可以根据之前用户发生的行为进行调整、优化。

交易机制

在互联网用户看到的每一个广告背后,都存在着一套精密且高效的互联网广告交易机制。以展示广告为例,如图2所示:

1. 在用户打开一个网页后,若网页中存在广告位,则网页发布者将发起一个广告请求。
2. 广告交易平台接到广告请求后,将对若干广告主发起竞价请求。
3. 广告主接到竞价请求后,通过分析广告位和用户的特征,结合自身广告的特征进行出价。
4. 广告交易平台接到广告主出价后,得出竞价结果并反馈给广告主。

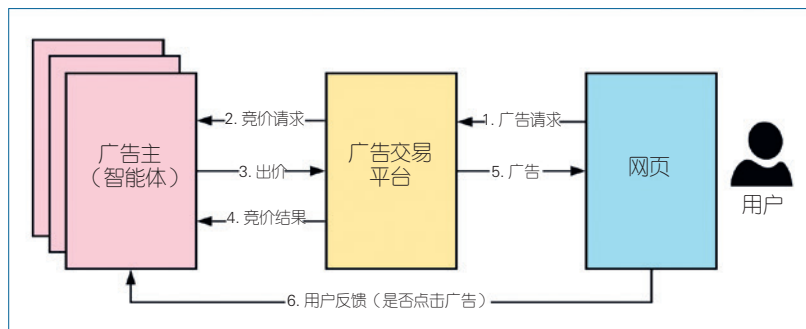


图2 展示广告的交易机制

5. 根据竞价结果, 胜出的广告被发送给网页发布者, 并呈现给用户。

6. 用户看到广告后, 是否点击广告将作为用户反馈被广告主收集。

在这个过程中, 除用户反馈外的整个广告交易流程通常在 0.1 秒的时间内完成, 即在用户打开网页的瞬间, 所需展示的广告已通过竞价产生并呈现。广告主的出价通常由一些智能出价算法完成。如果将广告主看作智能体, 则整个展示广告交易机制可被看作一个多智能体序列决策的环境。

搜索广告的交易机制与展示广告不同, 通常广告主出价由广告交易平台 (搜索引擎) 代理, 且出价高低与搜索关键词相关。信息流广告的交易机制与展示广告类似, 但广告主的出价策略也可能由广告交易平台 (或信息流应用) 代理。

计价规则

计算广告的计价规则主要有 CPM、CPC、CPA 三种, 分别针对不同的广告投放需求:

- CPM (Cost Per Mille) 按照每千次广告展示收费, 即广告每被展示 1000 次, 广告主需支付的价格。CPM 计价规则不考虑广告展示的即时效果, 因此主要用于重视长期价值的品牌广告展示。

- CPC (Cost Per Click) 按照每次点击收费, 即广告每被点击一次, 广告主需支付的价格。CPC 计价规则重视广告投放的即时用户反馈, 一定程度上将优化广告投放效果的责任交给了发布广告的媒体。CPC 计价规则适合重视广告即时效果的广告主使用。

- CPA (Cost Per Action) 按照每次订单收费, 即通过广告每促成广告主的业务发生一笔订单, 广告主需支付的价格。CPA 计价规则在 CPC 的基础上更加强调用户的真实反馈, 最大程度规避了广告主的风险。CPA 计价规则适合具备订单成交归因能力的广告主使用。

拍卖机制

计算广告的投放效果相对于传统广告更加有

效, 主要有两方面原因: 一是实时广告拍卖机制对广告价格的发现和广告位的分配, 二是机器学习对广告主、广告、广告位特征的利用。

一价和二价拍卖机制

拍卖是一种物品买卖的过程, 通常由多位竞价者出价, 再根据某种规则决定物品的归属和价格。常见的拍卖机制有一价拍卖和二价拍卖。

一价拍卖机制是一种朴素的拍卖机制, 出价最高者获得物品, 且实际付出的价格等于他自己的出价。在一价拍卖中, 竞价者有动机隐瞒自己对物品的真实估价, 这是因为如果最终胜出的竞价者稍微降低出价, 只要仍高于第二高价, 则可以更小的价格获取物品。因此, 一价拍卖机制不是一个讲真话 (truth-telling) 的拍卖机制。

与一价拍卖机制不同, 二价拍卖机制虽然也规定出价最高者获得物品, 但他只需要付出第二高出价。在二价拍卖中, 最高出价者无法通过降低自己的出价获得好处, 因此它是一个讲真话的拍卖机制。

VCG 拍卖机制

传统的一价和二价拍卖是针对单一物品, 当物品数量大于 1 时, 需要更复杂的拍卖机制。VCG (Vickrey-Clarke-Groves)^[5] 拍卖机制是二价拍卖机制的一种扩展, 它继承了讲真话的特性, 并实现了多物品拍卖的社会最优。

具体地, 假设有 N 位竞价者 $S=\{s_1, s_2, \dots, s_N\}$ 对 M 个物品 $T=\{t_1, t_2, \dots, t_m\}$ 进行拍卖, 对任意一个物品组合 $c \subseteq T$, 竞价者 s_i 的真实估价是 $v_{c_i}^i$ 。对于一个分配方案 $C_S^T=\{c_1, c_2, \dots, c_N\}$, 其中 c_i 表示分配给竞价者 s_i 的物品集合, 满足 $\bigcup_{i=1}^N c_i=T$ 。令 $V(C_S^T)=\sum_{i=1}^N v_{c_i}^i$ 表示分配方案 C_S^T 下的社会福利, 则存在一个使得社会福利最大化的最佳分配 $C_S^{T*}=\arg\max_{C_S^T} V(C_S^T)$, 此即 VCG 机制下的分配方案。在该分配方案下, VCG 机制规定每位竞价者 s_i 付出的价格为 $V(C_{S-\{s_i\}}^{T*})-V(C_{S-\{s_i\}}^{T-\{c_i\}*})$,

此处 c_i 表示 C_S^{T*} 分配方案下 s_i 获得的物品集合。该定价函数使得 s_i 付出的价格等于他对其余竞价者造

成的利益损失。

GSP 拍卖机制

虽然 VCG 拍卖机制是一种理想的多物品拍卖机制，但它的分配和定价函数较为复杂，不易被现实中的广告主理解。因此，广义二价拍卖机制 (Generalized Second-Price auction, GSP)^[1] 被提出并在搜索引擎中广泛应用。

GSP 拍卖机制针对的是一个特殊的多物品拍卖问题。该问题中，有 N 位竞价者拍卖 $K < N$ 个广告展示位。每个广告展示位被用户点击的概率为 a_i ，不妨令 a_1, a_2, \dots, a_k 。假设每个竞价者的出价为 b_1, b_2, \dots, b_N ，则出价为 b_1 的竞价者获得点击率为 a_1 的广告位，出价为 b_2 的竞价者获得点击率为 a_2 的广告位，以此类推。当广告被用户点击时，广告主才需要为广告付费，出价为 b_i 的广告主需要付出 b_{i+1} 的价格。

GSP 拍卖机制是二价拍卖机制的一种简单推广，但它并不具有二价拍卖机制的讲真话的特性。一个简单的例子是三位竞价者拍卖两个广告位，且 $a_1=1, a_2=0.5, v_1=5, v_2=4, v_3=1$ 。若讲真话，则 $b_1=5, b_2=4, b_3=1$ ，第一位竞价者的效用是 $u_1=a_1(v_1-b_2)=1$ 。而若第一位竞价者不讲真话，如令 $b_1=3$ ，则他将获得第二个广告位，效用将变为 $u_1=a_2(v_1-b_3)=2 > 1$ 。因此，第一位竞价者存在不讲真话的动机。

用户行为预测

广告效益预估与用户行为预测

计算广告场景中的效益预估，最核心的问题是用户反馈¹ 预估 (user response prediction)，即广告展示触达用户后，用户后续产生（正）反馈行为的概率，例如点击率 (Click-through Rate, CTR) 或购买转化率 (Conversion Rate, CVR)。对于广告主来说，用户如果产生了点击、转化等正向行为，那么广告主

的收益是正的；若用户没有产生任何相应的反馈行为，广告主则不会得到任何收益，反而需要承担广告的投放成本。同时，不同广告的用户行为价值又随着广告类型和内容的不同而有所区别。因此，在广告竞拍系统中，对于用户反馈行为概率较高的广告展示机会，广告主一般倾向于给出相对较高的竞拍价格去赢得本次广告展示机会；而对于用户反馈行为概率低的广告展示机会，广告主则倾向于给出低价竞拍，甚至不参与竞拍。

用户行为预测一般建模为一种二分类问题。不失一般性，本文将以用户“点击”行为为例进行阐述与说明，其他行为如“购买转化”等均可以类似的方案进行建模与优化。点击率预估，即判断“用户点击与否”的概率，可以用机器学习领域的二分类模型^[8,9] 进行建模与求解。这一阶段的主要目标是使预测更加精准，尽可能减少预测值与真实值的差别。当广告主针对广告展示的点击率进行预测之后，预测结果将作为收益预估的结果提供给下一阶段，进行下一阶段的预测或决策优化。

广告平台的数据

广告特征数据分为两类，一类是离散类别化数据 (discrete categorical data)，这一类数据占有了绝大部分比重。在广告平台上，用户、商品等信息一般均以表格化数据进行存储^[8]。如表 1 的示例，该广告的星期、性别、城市这三种特征信息，均为类别化数据。对于不同的样本，每种信息的取值只有一种或几种。另一类数据则是连续数值型数据 (continuous numerical data)，以实数值的形式进行存储与利用，例如商品价格、地理坐标等。

表 1 广告场景中的离散类别化数据示例

标签	星期	性别	其他特征	城市
点击 (1)	三	男	...	伦敦
未点击 (0)	一	男		上海
未点击 (0)	五	女		纽约

¹ 本文中“用户反馈”与“用户行为”表达的意思一致，均指用户观看广告后采取的点击或购买行为。

预估任务与机器学习解法

点击率预估作为广告场景中的核心问题^[9, 10], 业界广泛采用机器学习的方法来解决。表1最左侧的“标签”列展示了数据中用户点击与否的记录 y_i , 历史数据中用户产生点击则该样本标签为1, 否则为0。点击率建模了用户对广告主可能展示的广告内容的倾向性, 并且被用作广告主后续预算分配与出价决策^[11]的重要依据。

一般情况下, 点击率预估被建模为一个二分类概率估计问题, 即给定特征 x_i , 估计用户正反馈行为的概率 $\theta = \Pr(y_i=1|x_i)$ 。如图3所示, 根据输入的第 i 个样本特征 x_i , 点击率预估模型 f_Φ 将输出“用户点击与否”的概率预估值, 其中 Φ 为模型参数。模型训练目标则是将预测输出的似然概率与经验统计概率的偏差最小化。

随着广告场景特征的复杂化、多样化, 浅层模型依赖于人工特征工程, 耗时费力; 受建模能力的局限, 这些传统机器学习模型难以有效挖掘数据中的有效模式。而同时, 深度神经网络(深度学习)模型在模式识别领域^[12]的巨大成功逐渐吸引了研究者的注意。目前, 深度神经网络已经成为了点击率预估等用户行为预测问题的最有效解决方案。

FNN (Factorisation-machine supported Neural Networks)^[13]是首个将深度神经网络用于离散类别化数据建模的方法, 该模型将类别化特征进行独热编码(one-hot encoding)后输入神经网络, 并进行端到端(end-to-end)的优化。谷歌公司在同年提出了将浅层宽模型与深度模型进行结合并用于点击率预估任务的工作^[14], 在大规模工业实践中证明了深度神经网络模型的优越性。之后大量的深度神经网络相关的模型与方法被发表出来^[15-17]。如图4所示, CCPM (Convolutional Click Prediction Model)模型^[15]首次将模式识别领域较为成功的卷积神经网络(Convolutional Neural Network, CNN)模型迁移到了点击率预估工作中。DeepFM模型则综合了因




图3 点击率预估的问题定义




图4 神经网络用于点击率预估的架构图^[8]

式分解模型与深度模型的优点, 将深度神经网络结构与因式分解机模型结构进行结合, 有效提升了特征利用效率, 提高了点击率预估的准确性。PNN (Product-based Neural Network)模型^[16]基于因式分解机模型将神经网络的方法进行了改进, 在网络层中加入了特征向量乘法等操作, 极大地提高了点击率预估的准确率。然而这些深度神经网络的方法均基于静态的场景特征信息和用户信息进行建模与预估, 难以刻画用户与场景本身的动态性。最近, 有一些基于循环神经网络与记忆神经网络的工作被发表出来^[18-20], 这些工作对用户动态行为与历史信息进行建模, 实现了更为合理、精准的预估。

出价算法

一般竞价策略优化由一系列优化模块构成。第一部分是用户行为预测, 一般由机器学习的二分类模型进行建模与学习。第二部分是市场竞争建模, 一般由回归模型进行市场价格的建模与竞拍胜率预测。基于前两部分的预测结果, 第三部分竞价策略优化目标则是将用户点击数量^[21]或者广告主收益^[22]最大化。

传统的竞拍策略函数包括两种, 即真值竞拍策略函数^[23]与非真值线性竞拍策略函数^[24]。采用真值竞拍策略的广告主以点击收益乘以预估点击率得

出期望收益,并将期望收益作为竞拍价格参与竞拍。而线性竞拍策略则将预估的点击率与基准点击率进行校准,然后乘以基准竞拍价格。点击率预估的结果由上文提到的模型 $f(\cdot)$ 表示。

然而这两种竞拍策略并没有对广告投放效果进行优化。研究者针对这一问题提出了一系列基于优化理论的方案。竞拍策略优化一般建模为带约束的优化问题^[21, 22],并考虑其他的一些约束条件,例如广告投放的预算等。由最优化方法导出的竞拍策略函数一般不是线性竞拍函数,其最终表现则是在不同点击率预估结果的基础上做了非线性的映射函数 $b(\cdot)$,获得了最终的出价,如图5所示。

广告竞拍出价的过程本质上是一种连续决策过程,基于单次决策的最优化方法^[21]并非全局最优的解法。同时,由于决策过程是离散的动作,传统的机器学习方法对于离散输出难以通过基于梯度下降的方法进行优化。对于这种连续时间序列下的离散决策优化问题,研究发现可以使用马尔科夫决策过程(Markov Decision Process, MDP)进行建模与优化。目前,基于强化学习方法^[25]的连续决策优化在多种场景中表现出了卓越的性能^[26, 27],很多研究工作也将强化学习用于广告场景的竞拍策略优化^[28-30]。

其他应用

转化归因

在计算广告系统中,用户在最终转化或购买广告商品之前,往往会浏览一系列来自不同渠道的广告商品曝光(impression)。如图6所示,三位用户分别浏览了展示广告、搜索广告或来自多个渠道的推荐商品,其中用户2产生了最终的转化。对于用户接触一次广告曝光的行为,我们称之为广告触达(touch)。对于广告主来说,准确估计用户在网上浏览过程中不同的广告触达,对于用户最终转化行为的贡献值十分重要。这不仅有助于分析广告投放过程的投放效率,更能通过分析帮助指导后续广告投放的策略。




图5 竞拍策略函数 $b(\theta)$ 控制最终出价随着预估点击率 θ 的变化呈现非线性的变化^[21]

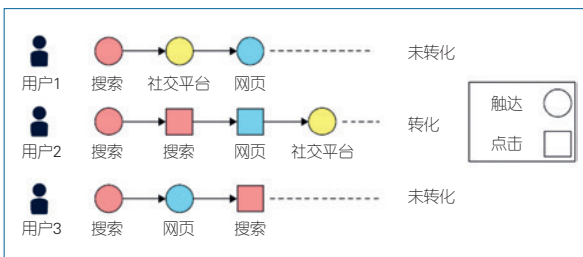


图6 用户在线行为导出的不同的结果

计算广告中,转化归因通常通过某些基于规则的方法计算,例如第一次点击或最后一次点击,然后根据获得的归因结果计算不同广告投放渠道的投资回报率(ROI),这可能会导致一些偏差^[31],因为实际上用户的最终转化一般由多次不同的广告触达共同作用影响。

近年来,有很多基于多触达转化归因(multi-touch conversion attribution)的工作发表,用于对各种广告投放渠道中的一系列触达点进行归因。第一个基于数据驱动的多点归因模型^[32]将用户浏览的广告信息输入分袋逻辑回归(bagged logistic regression)模型,预测用户转化率。其他一些工作主要基于简单分布假设的概率模型。

另一类多点归因模型基于“时间-事件”模型与生存分析理论^[33-35],它将不同时刻的用户转化行为事件建模为预测目标,并在考虑删失数据影响的同时,估计特定时间转化事件发生的概率。在最近的一些工

作中,基于深度神经网络的注意力机制的模型被提出,并用于建模转化归因与广告预算分配^[36,37]。

这些工作利用数据驱动的方法,将用户最终购买转化更加合理地归因于用户在平台的一系列广告触达序列上,这将极大促进广告主接下来的预算分配与广告投放策略的优化^[36]。

计算广告中的反欺诈技术

由于互联网广告中的特定付费模式可能存在作弊获利的漏洞,计算广告平台的反欺诈技术在领域内一直有很高的关注度。例如,针对 CPM 展示付费模式,媒体方可以用程序生成大量的虚假用户访问媒体页面,请求广告展示,从而赚取广告费用;针对 CPC 点击付费模式,作弊者则可以通过提交虚假搜索并点击竞争对手的搜索广告,从而快速耗尽其广告预算。这些作弊或欺诈行为将降低计算广告的投入产出比,损害整个计算广告市场的发展。如果一个广告平台的欺诈流量过多,则将会失去大量优质的广告主资源。根据 IAB 的报告^[38],美国互联网广告市场 2015 年总量 596 亿美元中有 46 亿美元的广告预算被浪费在“无效浏览”上,其中 70% 都是诸如 CPC、CPA 的效果广告,30% 是基于 CPM 的展示广告。

一般人工的反欺诈手段很难有效抑制不断更新升级的欺诈策略,机器学习技术成为了反欺诈的一个有力手段。由于个体的浏览、点击行为是否来自机器人是很难被精准标注的,计算广告的反欺诈技术主要来自无监督学习。例如美国的 Dstillery 广告技术公司研制出一种由媒体之间访问用户的覆盖率构成的共同访问网络 (co-visit network),来鉴定哪些媒体使用了机器人网络来骗取广告展示^[39]。该工作的基本假设是,一般正常用户在媒体网站之间的访问是随机的,这样两个媒体网站的共同访问用户的比例是很低的。而网络机器人由于来自为数不多的一些源头,所以使用了大量网络机器人作弊的媒体之间的共同访问用户比例就会不自然地提高。通过使用图聚类算法可以找到这样的作弊媒体群,从而加入广告投放的媒体黑名单中。

对于有监督学习技术,相比于用户或 IP 级别,媒体层面的人工标注要可行得多。例如 2012 年的手机端广告欺诈检测竞赛 (FDMA)^[40] 提供了一个基于新加坡媒体和广告平台 BuzzCity 的媒体广告欺诈三分类标注数据,其中健康流量媒体被标注为“正常”,被检查到可能刚开始使用机器人流量从而使流量统计偏离寻常区间的媒体被标注为“观察”,已经被确认使用了机器人流量的媒体被标注为“欺诈”。该竞赛旨在寻找一种有效的机器学习方案来给出媒体层面的欺诈检测。最终该竞赛的前几支队伍使用的模型为比较常见的支持向量机 (Support Vector Machine, SVM)、神经网络、梯度增强机 (Gradient Boosting Machine, GBM) 等。值得注意的是,不少重要的机器学习数据特征被挖掘出来,例如媒体访问的前序网址的统计、用户使用设备日活跃用户数量 (Daily Active User, DAU) 的统计、用户地域分布等特征。

展望未来

计算广告作为互联网生态的核心经济引擎,其稳定发展的重要性不言而喻。本文讨论了机器学习技术在计算广告领域的多方面落地,助力计算广告成为当今世界的第一大广告形式。展望计算广告的未来发展,我们认为以下几个结合机器学习技术的发展方向对于计算广告经济生态十分重要。

更全面的顾客旅程 (customer journey) 数据收集助力公平的转化归因,促进生态健康发展:当前大部分采用的最后触达归因 (last touch attribution) 机制导致了很多接近欺诈的广告展示策略。要让用户从品牌感知到商品消费的整个顾客旅程的每一环广告都健康发展,一个公平的归因机制是基础,而每个广告触达环节的数据收集对最终转化的归因至关重要。

多智能体强化学习和博弈论助力更优的市场机制的探索:对于广告主而言,每次广告出价是决策;对于媒体而言,每一次广告位拍卖的保留价设置是决策;对于用户而言,每次点击、购买是决策。多

方的长期决策优化可通过多智能体强化学习技术结合博弈论均衡理论来分析和模拟市场的动态演化,探索更好的市场机制设计。

远程监督和弱监督学习助力更加自动化、高效率的反欺诈技术:基于大量标注数据的有监督学习的方法无法应对日新月异的广告欺诈行为,而基于其他维度数据的远程监督学习技术和极少量标注样本的弱监督学习技术有望达成高度自动化的、数据利用效率高的欺诈行为检测,从而全面解决这一问题,改善计算广告的整体生态。 ■



张伟楠

CCF 专业会员。上海交通大学长聘教轨副教授。主要研究方向为(多智能体)强化学习、深度学习、数据科学、知识图谱及其互联网个性化服务、游戏智能等场景中的应用。wnzhang@sjtu.edu.cn



任侃

微软亚洲研究院研究员。主要研究方向为数据挖掘与机器学习,特别是序列建模与决策优化方法及其在计算广告、推荐系统与金融等领域的应用。kan.ren@microsoft.com



张海峰

北京大学前沿计算研究中心访问学者。主要研究方向为(多智能体)强化学习、计算广告、游戏智能体等。(本文通讯作者) haifeng.zhang@pku.edu.cn

参考文献

- [1] Benjamin E, Ostrovsky M, Schwarz M. Internet advertising and the generalized second-price auction: Selling billions of dollars worth of keywords[J]. *American Economic Review*, 2007, 1: 242-259.
- [2] PwC and Interactive Advertising Bureau. IAB internet advertising revenue report: 2018 full year results[R]. 2019.
- [3] Andrei Broder and Vanja Josifovski. Introduction to Computational Advertising[J]. *MS&E 239 Stanford University*. 2011.
- [4] Graepel T, Candela J Q, Borchert T, et al. Web-scale bayesian click-through rate prediction for sponsored search advertising in microsoft's bing search engine[C]// International Conference on International Conference on Machine Learning, Omnipress, 2010.
- [5] Groves T. Incentives in Teams[J]. *Econometrica*, 1973, 41(4):617-631.
- [6] He X, Pan J, Jin O, et al. Practical lessons from predicting clicks on ads at facebook[C]// Proceedings of the Eighth International Workshop on Data Mining for Online Advertising, 2014: 1-9.
- [7] McMahan H. Brendan, Holt G, Sculley D, et al. Ad click prediction: a view from the trenches[C]// Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining, 2013: 1222-1230.
- [8] Qu Y, Fang B, Zhang W, et al. Product-based neural networks for user response prediction over multi-field categorical data[J]. *ACM Transactions on Information Systems (TOIS)*, 2018, 37 (1): 1-35.
- [9] Lee K C, Orten B B, Dasdan A, et al. Estimating conversion rate in display advertising from past performance data[C]// Proceedings of the 18th ACM SIGKDD international conference on Knowledge discovery and data mining, 2012: 768-776.
- [10] McMahan H B, Holt G, Sculley D, et al. Ad click prediction: a view from the trenches[C]// Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining, 2013: 1222-1230.
- [11] Richardson, Matthew, Ewa Dominowska, and Robert Ragno. "Predicting clicks: estimating the click-through rate for new ads." In Proceedings of the 16th international conference on World Wide Web, pp. 521-530. 2007.
- [12] LeCun, Yann, Yoshua Bengio, and Geoffrey Hinton. "Deep learning." *nature* 521, no. 7553 (2015): 436-444.
- [13] Zhang, Weinan, Tianming Du, and Jun Wang. "Deep learning over multi-field categorical data." In European conference on information retrieval, pp. 45-57. Springer, Cham, 2016.
- [14] Cheng, Heng-Tze, Levent Koc, Jeremiah Harmsen, Tal Shaked, Tushar Chandra, Hrishikesh Aradhye, Glen Anderson et al. "Wide & deep learning for recommender systems." In Proceedings of the 1st workshop on deep learning for recommender systems, pp. 7-10. 2016.
- [15] Liu, Qiang, Feng Yu, Shu Wu, and Liang Wang. "A convolutional click prediction model." In Proceedings of the 24th ACM international on conference on information and knowledge management, pp. 1743-1746. 2015.
- [16] Qu, Yanru, Han Cai, Kan Ren, Weinan Zhang, Yong

- Yu, Ying Wen, and Jun Wang. "Product-based neural networks for user response prediction." In 2016 IEEE 16th International Conference on Data Mining (ICDM), pp. 1149-1154. IEEE, 2016.
- [17]Guo, Huifeng, Ruiming Tang, Yunming Ye, Zhenguo Li, and Xiuqiang He. "DeepFM: a factorization-machine based neural network for CTR prediction." arXiv preprint arXiv:1703.04247 (2017).
- [18]Zhou, Guorui, Xiaoqiang Zhu, Chenru Song, Ying Fan, Han Zhu, Xiao Ma, Yanghui Yan, Junqi Jin, Han Li, and Kun Gai. "Deep interest network for click-through rate prediction." In Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, pp. 1059-1068. 2018.
- [19]Ren, Kan, Jiarui Qin, Yuchen Fang, Weinan Zhang, Lei Zheng, Weijie Bian, Guorui Zhou et al. "Lifelong Sequential Modeling with Personalized Memorization for User Response Prediction." In Proceedings of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval, pp. 565-574. 2019.
- [20]Qin, Jiarui, Kan Ren, Yuchen Fang, Weinan Zhang, and Yong Yu. "Sequential Recommendation with Dual Side Neighbor-based Collaborative Relation Modeling." In Proceedings of the 13th International Conference on Web Search and Data Mining, pp. 465-473. 2020.
- [21]Zhang, Weinan, Shuai Yuan, and Jun Wang. "Optimal real-time bidding for display advertising." In Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining, pp. 1077-1086. 2014.
- [22]Ren, Kan, Weinan Zhang, Ke Chang, Yifei Rong, Yong Yu, and Jun Wang. "Bidding machine: Learning to bid for directly optimizing profits in display advertising." IEEE Transactions on Knowledge and Data Engineering 30, no. 4 (2017): 645-659.
- [23]Chen, Ye, Pavel Berkhin, Bo Anderson, and Nikhil R. Devanur. "Real-time bidding algorithms for performance-based display ad allocation." In Proceedings of the 17th ACM SIGKDD international conference on Knowledge discovery and data mining, pp. 1307-1315. 2011.
- [24]Perlich, Claudia, Brian Dalessandro, Rod Hook, Ori Stitelman, Troy Raeder, and Foster Provost. "Bid optimizing and inventory scoring in targeted online advertising." In Proceedings of the 18th ACM SIGKDD international conference on Knowledge discovery and data mining, pp. 804-812. 2012.
- [25]Sutton, Richard S., and Andrew G. Barto. Reinforcement learning: An introduction. MIT press, 2018.
- [26]Mnih, Volodymyr, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves et al. "Human-level control through deep reinforcement learning." Nature 518, no. 7540 (2015): 529-533.
- [27]Silver, David, Aja Huang, Chris J. Maddison, Arthur Guez, Laurent Sifre, George Van Den Driessche, Julian Schrittwieser et al. "Mastering the game of Go with deep neural networks and tree search." nature 529, no. 7587 (2016): 484.
- [28]Cai, Han, Kan Ren, Weinan Zhang, Kleanthis Malialis, Jun Wang, Yong Yu, and Defeng Guo. "Real-time bidding by reinforcement learning in display advertising." In Proceedings of the Tenth ACM International Conference on Web Search and Data Mining, pp. 661-670. 2017.
- [29]Wu, Di, Xiujun Chen, Xun Yang, Hao Wang, Qing Tan, Xiaoxun Zhang, Jian Xu, and Kun Gai. "Budget constrained bidding by model-free reinforcement learning in display advertising." In Proceedings of the 27th ACM International Conference on Information and Knowledge Management, pp. 1443-1451. 2018.
- [30]Jin, Junqi, Chengru Song, Han Li, Kun Gai, Jun Wang, and Weinan Zhang. "Real-time bidding with multi-agent reinforcement learning in display advertising." In Proceedings of the 27th ACM International Conference on Information and Knowledge Management, pp. 2193-2201. 2018.
- [31]Chandler-Pepelnjak, John. "Measuring roi beyond the last ad." Atlas Institute Digital Marketing Insight (2009): 1-6.
- [32]Shao, Xuhui, and Lexin Li. "Data-driven multi-touch attribution models." In Proceedings of the 17th ACM SIGKDD international conference on Knowledge discovery and data mining, pp. 258-264. 2011.
- [33]Zhang, Ya, Yi Wei, and Jianbiao Ren. "Multi-touch attribution in online advertising with survival theory." In 2014 IEEE International Conference on Data Mining, pp. 687-696. IEEE, 2014.
- [34]Ji, Wendi, and Xiaoling Wang. "Additional multi-touch attribution for online advertising." In Thirty-First AAAI Conference on Artificial Intelligence. 2017.
- [35]Ji, Wendi, Xiaoling Wang, and Dell Zhang. "A probabilistic multi-touch attribution model for online advertising." In Proceedings of the 25th ACM International on Conference on Information and Knowledge Management, pp. 1373-1382. 2016.
- [36]Ren, Kan, Yuchen Fang, Weinan Zhang, Shuhao Liu,

- Jiajun Li, Ya Zhang, Yong Yu, and Jun Wang. "Learning multi-touch conversion attribution with dual-attention mechanisms for online advertising." In Proceedings of the 27th ACM International Conference on Information and Knowledge Management, pp. 1433-1442. 2018.
- [37]Zhou, Yichao, Shaunak Mishra, Jelena Gligorijevic, Tarun Bhatia, and Narayan Bhamidipati. "Understanding consumer journey using attention based recurrent neural networks." In Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, pp. 3102-3111. ACM, 2019.
- [38]Interactive Advertising Bureau. What is an untrustworthy supply chain costing the us digital advertising industry?[R]. 2015.
- [39]Stitelman, Ori, Claudia Perlich, Brian Dalessandro, Rod Hook, Troy Raeder, and Foster Provost. "Using co-visitation networks for detecting large scale online display advertising exchange fraud." In Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining, pp. 1240-1248. 2013.
- [40]Oentaryo, Richard, Ee-Peng Lim, Michael Finegold, David Lo, Feida Zhu, Clifton Phua, Eng-Yeow Cheu et al. "Detecting click fraud in online advertising: a data mining approach." The Journal of Machine Learning Research 15, no. 1 (2014): 99-140.